

SISTEMA AUTOMATIZADO DE **PREDICCIÓN Y** **PRIORIZACIÓN CLÍNICA EN** **MAMOGRAFÍAS MEDIANTE** **INTELIGENCIA ARTIFICIAL**

Máster de Especialización en Inteligencia Artificial y Big Data

Jaime López Gavira



Centro Oficial FP
Tecnología y Digitalización

ÍNDICE

Resumen	4
Introducción	4
2. Contextualización y justificación.....	5
2.2. Objetivos	7
3.Marco teórico.....	8
3.1. Redes Neuronales Convolucionales y Arquitectura ResNet50V2	8
3.2. Mecanismos de atención espacial.....	8
3.3. Sistemas de información y reporte de datos de Imagen Mamaria.....	9
3.4. Tratamiento de clases desbalanceadas mediante Focal Loss.....	9
CAPITULO 1: DESCRIPCIÓN DEL DATASET Y HERRAMIENTAS.....	10
1.1. Fuentes de datos utilizadas	10
1.2. Estructura de las clases	11
1.3. Entorno de desarrollo y herramientas tecnológicas	12
CAPITULO 2: ANÁLISIS EXPLORATORIO (EDA) Y PREPROCESAMIENTO DE IMAGEN.....	13
2.1. Análisis Exploratorio de Datos (EDA)	13
2.2. Algoritmo de Limpieza y Segmentación	14
2.3. Aplicación del filtro CLAHE para la mejora del contraste	14
2.4. Comparativa Visual y Normalización Final	14
CAPÍTULO 3: DESARROLLO DE LA ARQUITECTURA Y ENTRENAMIENTO	17
3.1. Arquitectura del Modelo: ResNet50V2 y Transfer Learning	17
3.2. Módulo de Atención Espacial Personalizado	17
3.3. Focal Loss y Pesos de Clase	18
3.4. Early Stopping y Model Checkpoint.....	18
CAPÍTULO 4: EVALUACIÓN DE RESULTADOS E INTERFAZ DE USUARIO	20
4.1. Análisis de Métricas y Curvas de Aprendizaje.....	20
4.2. Interpretación de la Matriz de Confusión	20
4.3. Despliegue Práctico interfaz de “Radiology AI suite”	22



Centro Oficial FP
Tecnología y Digitalización

Conclusiones del proyecto	24
BIBLIOGRAFÍA	26

En un mundo lleno de etiquetas, este trabajo va dedicado para el “jornalero”
y para la “ama de casa” aunque la verdadera etiqueta que llevan en las
de héroes.

A mi hermano por dejarme de pequeño robarle su portátil para
introducirme en la informática.

A mi pareja por quedarse despierta junto a mí tantas noches donde
pasaban las horas y los códigos se hacían eternos.

A esas guerras de lazo rosa, ojalá ser tan fuerte como vosotras.

Miguel, Manuel, Andrés la etiqueta de docencia se os queda pequeñas,
sois maravillosos gracias por guiarme por este camino.

Resumen

Este trabajo final de grado presenta el desarrollo de un modelo que he entrenado de inteligencia artificial para la detección mamografías clasificándolas así en categorías diferentes con la finalidad de encontrar tumores en mamografías y evitar el fallo humano.

Se ha decidido elaborar este modelo ya que soy una persona que vive mucho emocionalmente las cosas y cuando vi en las noticias la temeridad ocurrida en Andalucía con el cáncer de mama decidí que era la forma perfecta para aportar mi pequeño grano de arena a la causa.

Se ha desarrollado un sistema de clasificación de mamografías basado en **ResNet50V2** con un **Módulo de Atención Espacial** para detectar masas y calcificaciones. La metodología empleó preprocesamiento **CLAHE** y la función **Focal Loss** para gestionar el desbalanceo de los Datasets **CBIS-DDSM** y **Vindr**. El modelo ha llegado a alcanzar un **AUC de 0,93** bajo la nomenclatura **BI-RADS**, demostrando que la integración de mecanismos de atención optimiza la precisión en el diagnóstico oncológico automatizado.

Hablando de la parte moral podemos considerar que este ha sido un desarrollo de IA Ética ya que su finalidad es que en un contexto clínico se utilizan los datos para prevenir y salvar vidas. Respecto a su confianza podemos observar que esta IA realiza una serie de pruebas y ajustes para dar la máxima confianza posible. Finalmente, respecto a la responsabilidad podemos observar que esta IA no utiliza materiales externos que puedan dañar a personas o medioambiente.

Introducción

Desde pequeño me ha apasionado el mundo de la biología (que se lo pregunten a mi vecino Miguel), aunque el camino me separó de esta pasión considero que no puedes sacar la pasión de dentro de la persona. Es más, considero que si no me hubiese decantado por la informática hoy en día sería biólogo.

No son caminos tan lejanos como pensaba. Cuando me metí en el mundo de los datos observé que realmente está vinculado con todo lo que nos rodea. Vivo en Marchena, un



Centro Oficial FP
Tecnología y Digitalización

humilde pueblo de Sevilla donde como todos hemos visto en las noticias “Amama eleva a 4.000 las mujeres afectadas por los fallos en el cribado de cáncer de Andalucía y prepara 200 denuncias”. El leer esto me partía el alma; Podrían ser mi madre, mi abuela.

El problema lo encontré cuando vi que pasó de ser un problema real a un problema político, amenazando con cifras como si no se tratasen de vidas humanas ambos lados.

¿Ahí pensé en lo siguiente “y si programo un modelo de inteligencia artificial que analice las mamografías?” Pensé que podría ahorrar tiempo al médico y el establecer un orden de citas y ojalá se tuviese en cuenta algo así a gran escala para salvar vidas.

En estos últimos años el exponencial avance de accesibilidad a datos y de los nuevos modelos de lenguajes nos abrimos a unas posibilidades de abarcar este tipo de tareas.

A lo largo de este documento voy a tratar de explicar de la manera más sencilla como se ha construido el sistema, el porqué de las decisiones tomadas y el cómo funciona basándonos en los resultados obtenidos. Adicionalmente trataré de nombrar las ventajas y desventajas que yo mismo le encuentro.

2. Contextualización y justificación

Las mamografías según la RAE se definen como “Radiografía de mama en película de grano fino, capaz de obtener imágenes de tejidos blandos con gran precisión.” Son una prueba clínica esencial para cuidar la salud de las personas. Siendo honestos considero que automatizar este complejo procedimiento puede suponer un antes y un después en este ámbito. Tengo amigos que han estudiado rayos y ellos mismos dicen que algo así sería genial.

Explicaré un poco la parte técnica de cómo se hacen y que mecanismo lleva detrás, pero es algo prescindible para aquel que no esté interesado en el tema puede saltarse libremente esta parte.

PROCEDIMIENTO DE LA PRUEBA

Para llevar a cabo una mamografía, la mama se coloca en una máquina especial llamada mamógrafo. Esta máquina está diseñada para que los rayos X atraviesen la mama y se



Centro Oficial FP
Tecnología y Digitalización

capture la imagen. En los mamógrafos digitales modernos, la imagen se captura directamente en un detector digital en lugar de una película.

Para cada exposición, la mama se comprime, lo que permite obtener una imagen más clara y nítida, reducir la dosis de radiación y minimizar el movimiento. Los mamógrafos 3D más avanzados pueden realizar un estudio tridimensional de la mama (tomosíntesis), lo que mejora la precisión diagnóstica y la detección de cánceres en estadios iniciales.

Así se consigue, además, detectar tumores ocultos en la mamografía convencional. Con este fin se suele emplear también la ecografía y de esta manera realizar un diagnóstico más fiable y preciso de la mama.

PREPARACIÓN DE LA MAMOGRAFÍA

Prepararse adecuadamente para una mamografía es esencial para obtener resultados precisos. Si tiene alguna mamografía anterior, es muy importante llevarla para su comparación con el nuevo estudio. A continuación, detallamos algunas indicaciones previas para tener en cuenta:

Es recomendable evitar el uso de desodorantes, cremas o lociones en las axilas o el pecho el día del examen, ya que estos productos pueden interferir con la calidad de la imagen.

Lleve ropa cómoda y fácil de quitar, y considere programar la mamografía en un momento del mes en el que los senos no estén sensibles, como después del período menstrual.

Informe al personal si tiene implantes mamarios o algún historial de cirugías de mama para que puedan tomar precauciones adicionales durante el examen.

Siguiendo estos pasos, ayudará a que el procedimiento sea más rápido y preciso.

Volviendo después de esta explicación llego a una serie de conclusiones:

El problema médico principal que nos encontramos es como el cáncer de mama es una de las principales causas de mortalidad en mujeres y la detección precoz de este nos va a ser fundamental para aumentar la vida de nuestras mujeres.



Centro Oficial FP
Tecnología y Digitalización

Yo mismo haciendo este trabajo he sentido una fatiga gigante intentando descifrar por mí mismo. Así que un radiólogo, que ve cientos al día puede hacer que su precisión false y de falsos positivos o negativos a los pacientes.

Si todos los sectores se están expandiendo, podríamos aplicarlo a la medicina de una manera más prioritaria que de otros campos. En un contexto tan importante como lo es la capacidad de salvar vidas humanas y en muchos otros casos facilitarlas bajo mi punto de vista deberíamos invertir nuestros recursos y tiempo en algo tan importante que en algunos casos va a poder salvar vidas o mejorar la calidad de estas.

He tratado a petición y recomendación de mi amigo Antonio (con formación en radiología) utilizar una nomenclatura BI-RADS una clasificación de sistema clínico real que haría que cualquier experto en un hospital entendiese esto.

2.2. Objetivos

Mis objetivos son desarrollar un sistema lo suficientemente preparado para ser capaz de realizar una detección de anomalías en mamografías mediante un aprendizaje profundo que se basará en una arquitectura ResNet50V2 (ver bibliografía) encargada de la clasificación de imágenes (en este caso mamografías) para etiquetarlas como malignas, benignas o normales.

Entre los objetivos específicos de los que me he informado ayudado de compañeros expertos en la materia y de la propia IA que considero una herramienta voy a destacar los siguientes:

1. Ser capaz de implementar un procesamiento avanzado utilizando técnicas de **CLAHE** para la mejora de contraste y limpieza de artefactos en las imágenes médicas.
2. Intentar enfocar el modelo en que se enfoque en regiones de interés como las anomalías, masas, etc... E ignore el tejido que consideremos sano al que trataremos como ruido.
3. Abarcar un problema muy importante como el desbalanceo de clases usando un **Focal Loss** algo muy usado en este tipo de materia.
4. Evaluar el rendimiento de este modelo usando métricas robustas como el **Área bajo la curva de ROC** y matrices de confusión.

3.Marco teórico

La inteligencia artificial en esta última década ha pasado de ser una herramienta experimental para ir poco a poco convirtiéndose en un pilar fundamental de los Sistemas de Soporte a la Decisión Clínica. Dentro de la IA nos encontramos el Deep Learning (Aprendizaje profundo) que nos ha demostrado que tiene una capacidad enorme para los datos no estructurados como es en este caso las imágenes médicas. A diferencia de muchos métodos las redes neuronales profundas nos permiten identificar una serie de patrones en los píxeles que nuestro propio ojo podría no ser capaz de ver. Esto hace que tengamos una segunda opción muy importante para salvar vidas como en este caso para pacientes con cáncer de mama.

3.1. Redes Neuronales Convolucionales y Arquitectura ResNet50V2

Este proyecto utiliza una arquitectura ResNet50V2 que es una evolución de redes residuales que introduce una serie de conexiones de salto. Estas permiten que el gradiente fluya más fácilmente durante el entrenamiento solucionando el problema de desvanecimiento del gradiente que nos podemos encontrar en redes muy profundas.

Adicionalmente hemos empleado el Transfer Learning que utiliza pesos preentrenados que permite que nuestro modelo aproveche los conocimientos previos sobre formas y texturas básicos lo cual acelera la convergencia y mejora la precisión para un tema como este de la radiología mamaria.

3.2. Mecanismos de atención espacial

Uno de los aportes más técnicos que he realizado aquí por recomendaciones ajenas es un Módulo de Atención Espacial. En una mamografía que pueda contener alguna enfermedad nos tenemos que encontrar por tanto una región con una anomalía. Esta región ocupa solo una pequeña parte o fracción de la imagen respecto a la mamografía entera. Estos mecanismos permiten que la red neuronal aprenda a asignar pesos

diferenciados a distintas regiones de la misma imagen haciendo así que este enfocando su capacidad de cómputo y decisión en las zonas sospechosas suprimiendo así la información irrelevante.

3.3. Sistemas de información y reporte de datos de Imagen Mamaria

Mi principal duda fue, ¿Cómo le doy a Antonio este proyecto y que sepa usarlo? Ahí entró en juego la siguiente idea. Para asegurar una utilidad real, una utilidad clínica de este modelo se opta por una nomenclatura BI-RADS (Sistema de información y datos sobre imágenes mamarias) un estándar desarrollado por el Colegio Americano de Radiología que nos permite una comunicación clara y consistente entre profesionales médicos.

3.4. Tratamiento de clases desbalanceadas mediante Focal Loss

En el ámbito de la imagen médica hay un problema enorme que yo mismo me he encontrado anteriormente: el desbalanceo entre clases. Nos podemos encontrar muchos más casos normales que con patología o viceversa. Para evitar que el modelo tire hacia lo que dice la mayoría aplicamos el Focal Loss.

A diferencia de la **entropía** concepto que se puede definir como un criterio de pureza que cuantifica la incertidumbre, desorden o impureza en un conjunto de datos. La Focal Loss introduce un factor de modulación que reduce la contribución de los ejemplos normales y aumenta el peso a los ejemplos malignos para así obligar al modelo a centrarse en mejorar la precisión de las muestras críticas. De una forma mas matemática se obliga al modelo a centrarse en mejorar la precisión en pruebas con riesgo algo que es fundamental para evitar falsos negativos que en un caso como este puede llegar a costar una vida.

CAPITULO 1: DESCRIPCIÓN DEL DATASET Y HERRAMIENTAS

1.1. Fuentes de datos utilizadas

Para el desarrollo de esta modelo he configurado dos Datasets convirtiéndolos en uno solo lo que podríamos considerar como un Dataset híbrido el cual combina dos fuentes de referencia mundial en el ámbito de la mamografía digital, aunque ¡OJO! Al haber sido importados directamente de Kaggle han podido sufrir alguna modificación en sus metadatos respecto al original. Con esto quiero aclarar que para este trabajo no se ha usado una fuente “oficial” en toda la definición de la palabra.

- **TCGA-CBIS-DDSM (Curated Breast Imaging Subset of DDSM):** Esta es la primera de las dos bases de datos que nos encontramos en nuestro proyecto. Ha sido utilizada como la fuente principal de muestras en las cuales se ha procesado registros clínicos correspondientes tanto a calcificaciones como a masas. El proceso de carga ha sido directamente mediante *kagglehub* el cual nos ha permitido ingresar una cantidad de 2864 registros de manera inicial con una serie de metadatos clínicos.

```
print("Iniciando la descarga de todas las imágenes y archivos del dataset...")

path = kagglehub.dataset_download("awsaf49/cbis-ddsm-breast-cancer-image-dataset")

print("=====")
print("¡Descarga completada con éxito!")
print("Ruta de los archivos del dataset:", path)
print("=====")
```

- **Vindr-Mammo:** He usado este segundo Dataset por algo muy importante. El primero no tenía imágenes con un tejido completamente sano. De esta fuente he extraído imágenes sanas clasificadas con la categoría de **BI-RADS 1**. Esto nos asegura que el modelo aprenda a distinguir entre anomalías y anatomía mamaria estándar.

```
# 1. Descargar el dataset PNG
print("Descargando dataset...")
path_vindr = kagglehub.dataset_download("shantanughosh/vindr-mammogram-dataset-dicom-to-png")
print("Dataset guardado en disco:", path_vindr)


# 2. Cargar el CSV de anotaciones desde GitHub
csv_url = "https://raw.githubusercontent.com/batmanlab/Mammo-CLIP/main/src/codebase/data_csv/vindr_detection_v1_folds.csv"
df_vindr = pd.read_csv(csv_url, low_memory=False)
```

No es bueno mezclar Datasets y mucho menos en un caso clínico. La razón para hacerlo en este caso es porque se trata de un ensayo. A la hora de realizar procesos oficiales debemos evitar en la medida de lo posible esto y si en algún caso se acaba realizando verificar que son idénticos en estructura.

1.2. Estructura de las clases

En este trabajo nos vamos a encontrar una agrupación de categorías donde se simplificó la clasificación clínica de las etiquetas **Benign** y **benign_withut_callback** en una sola categoría llamada **Benigno**. La razón de esto fue la propia dificultad que tenía el modelo en la distinción de estos ya que podía ser a nivel de un solo píxel. Por tanto, se optó por optimizar el modelo reduciendo las clases a una sola.

En cuanto al equilibrado de este modelo nos encontramos un 1:1 es decir, todas las clases tienen el mismo número de imágenes siendo 578 en este caso. Para la categoría de benigno se descargó 578 de cada tipo, pero a la hora de unificar la clase se dividieron entre dos cada una dando 289 registros los cuales se mezclaron para conseguir un equilibrado 1:1 antes de la mezcla de clases y adicionalmente se consiguió mantener el equilibrado global.



1.3. Entorno de desarrollo y herramientas tecnológicas

El entorno de desarrollo en este caso se ha realizado en **Google Colab** un servicio gratuito en la nube de Google que permite escribir y ejecutar código Python en el navegador sin configuración previa.

El lenguaje utilizado en este caso ha sido Python que gracias a su sintaxis sencilla e intuitiva y su ecosistema de bibliotecas especializadas (Pandas, NumPy, Stickit-learn...) podemos considerarlo el rey de la ciencia de datos e IA. Además de por ser gratuito, de código abierto, versátil y que cuenta con una comunidad enorme que facilita el aprendizaje.


Utilizo una serie de Frameworks creados para Deep Learning desarrollando la arquitectura y entrenamiento con TensorFlow y Keras, utilizando la API funcional para la creación de atención personalizadas.

En cuando al procesamiento de datos utilizamos unas librerías como Pydicom y OpenCV para manipular las imágenes en formato médico y utilizamos Pandas para la parte analítica y de limpieza de los metadatos clínicos asociados.

CAPITULO 2: ANÁLISIS EXPLORATORIO (EDA) Y PREPROCESAMIENTO DE IMAGEN

2.1. Análisis Exploratorio de Datos (EDA)

Antes de comenzar con el entrenamiento una práctica muy recomendada es comprender la naturaleza y la distribución de los datos.



Distribución de las tres categorías diagnósticas tras el balanceo dinámico (578 muestras por clase).

En el análisis de la distribución podemos observar que las 3 clasificaciones finales (Como he comentado previamente benigno se unificará) sean idénticas en cuanto a representaciones. Este diseño experimento es fundamental en la medicina para asegurar que la precisión del modelo no presente discriminación a una clase por desbalanceo.



Centro Oficial FP
Tecnología y Digitalización

2.2. Algoritmo de Limpieza y Segmentación

Las mamografías que vemos suelen contener una gran cantidad de ruido para ser analizadas por un modelo. Esto se debe a que contiene factores irrelevantes para el análisis como por ejemplo el aire negro de fondo, las etiquetas de identificación...

Por tanto, se ha desarrollado una función de limpieza técnica que utiliza la detección de contornos mediante OpenCV para segmentar únicamente la anatomía de la mama.

Este proceso no solo reduce un coste computacional al disminuir el ruido, sino que además evita que la red neuronal aprenda patrones falsos. Asimismo, el recorte ayuda a minimizar presencias al punto que ayude a la IA a que no confunda un simple músculo pectoral con unas densidades que pueda creer que son tumores.

2.3. Aplicación del filtro CLAHE para la mejora del contraste

El desafío técnico que nos encontramos en estas imágenes formato DICOM nos encontramos una alta tasa de bits (16 bits), lo que nos puede resultar en una visualización de bajo contraste para un modelo estándar. Para intentar eliminar este problema aplicamos un algoritmo CLAHE (Ecuación adaptativa del histograma con contraste limitado).


CLAHE opera en pequeñas regiones de la imagen mejorando así el contraste local de manera adaptativa. Esta técnica es crítica para resaltar microcalcificaciones y espículas de masas malignas que podrían quedar ocultas en una imagen plana.

Su principal función es prevenir la atenuación de características sutiles (como las microcalcificaciones pleomórficas) al comprimir el rango dinámico de las imágenes originales


2.4. Comparativa Visual y Normalización Final

El impacto del pipeline de procesamiento es evidente al comparar las muestras originales con las procesadas.


Original (BENIGN_WITHOUT_CALLBACK)




Transformada: CLAHE + Recorte




Original (BENIGN)




Transformada: CLAHE + Recorte



Original (MALIGNANT)



Transformada: CLAHE + Recorte





Centro Oficial FP
Tecnología y Digitalización

Izquierda: Mamografía original. Derecha: Mamografía tras aplicación de recorte y CLAHE.

Como se puede observar en esta imagen el tejido mamario adquiere una definición superior. Finalmente, para garantizar la compatibilidad con la arquitectura ResNet50V2, se realizó una normalización de píxeles al rango $[-1, 1]$ ya que un mieda era el peso de los píxeles blancos sobre los negros y un redimensionamiento a 224x224 píxeles con tres canales de color (RGB).

CAPÍTULO 3: DESARROLLO DE LA ARQUITECTURA Y ENTRENAMIENTO

3.1. Arquitectura del Modelo: ResNet50V2 y Transfer Learning

La arquitectura que utiliza este modelo, el núcleo de este es la arquitectura **ResNet50V2**. Ha sido seleccionada por su capacidad para mitigar el desvanecimiento del gradiente mediante una serie de conexiones residuales, es decir, imaginamos el juego del teléfono, una persona le dice la palabra a otro e intentamos que la última persona reciba el mensaje de la inicial. En este caso cuanto más persona más difícil es que llegue bien a su destino. Aquí en las redes neuronales es algo parecido, contra más capas más información se va perdiendo y el modelo peor aprende. Pero esta arquitectura particularmente introduce unas conexiones que son como unos atajos para saltar de capas y llegar directamente más adelante sin perderse por el camino.

Se ha empleado **Transfer Learning** con pesos de ImageNet, permitiendo que la red posea una base sólida en detección de bordes y texturas antes de especializarse en el dominio mamográfico.

3.2. Módulo de Atención Espacial Personalizado

A diferencia de cualquier red neuronal estándar en este modelo nos encontramos un módulo de atención espacial desarrollado mediante una API funcional de Keras. Para explicar la función de este componente, actúa como un mecanismo que mitiga el ruido de fondo, es decir elimina el tejido normal, borra el oxígeno, etc... De esta forma fuerza a priorizar características que presenten algún tipo de anomalía en su forma. Nos optimiza la capacidad de la red para que esta encuentre lesiones que pueden pasar desapercibidas o inalcanzables en arquitecturas convencionales.

3.3. Focal Loss y Pesos de Clase

Ahora hablemos de dos de los puntos los cuales considero mas importantes o de más relevancia para el entrenamiento. Configuré 50 épocas para el entrenamiento de varias formas posibles y en todas me encontraba un error común: El desbalanceo clínico.

El desbalanceo clínico es la diferencia numérica real entre la cantidad de pacientes que nos encontramos con algún tipo de anomalía o pacientes sin ninguna. Para esto busqué varias soluciones y me quedé con estas dos:

1. Focal Loss: En lugar de una perdida estándar, he implementado esta función porque es muy efectiva en medicina. Su función es reducir el peso de los casos fáciles, es decir, con tejido sano y por tanto centrar el aprendizaje en aquellos más difíciles de clasificar.
2. Pesos clínicos: Seamos sinceros, he configurado a mano un peso de 3 a los errores de la clase maligna. Que he buscado con ello una inclinación intencionada hacia una alta sensibilidad. Las razones son sencillas, asumo que un falso negativo en un caso tan importante como es el diagnóstico de una prueba que puede costar la vida a una persona es mucho mas grave que un falso positivo ya que estamos hablando de cáncer.

3.4. Early Stopping y Model Checkpoint

¡Ojo! No ha sido nada fácil. Un problema enorme que me he encontrado en el entrenamiento es que el modelo tendía a memorizar en casi todo momento. Para asegurarnos que no ocurriese Overfitting (memorización de datos) y que el modelo mantuviese una alta capacidad de generalización ante nuevas imágenes implementamos el Early Stopping (Parada temprana).

Esta técnica vamos a asemejarla con un rebaño de ovejas, es como el perro pastor que monitorea inteligentemente si sus ovejas pastan de forma correcta. He configurado el sistema para observar la pérdida de validación (`val_loss`); si esta métrica no mejora tras un número determinado de épocas (parámetro `patience`), el entrenamiento se detiene automáticamente.



Centro Oficial FP
Tecnología y Digitalización

Con estos campos se logra lo siguiente:

1. **Optimizar el tiempo de cómputo** ya que se evitan ciclos de entrenamiento innecesarios cuando la red ya ha alcanzado su punto óptimo.
2. **Tratar de garantizar la mejor versión del modelo** ya que con la función de **Model Checkpoint** guardo los pesos de la época con mejor rendimiento clínico.


```
# Early Stopping para evitar overfitting  
callback_parada = EarlyStopping(monitor='val_loss', patience=8, restore_best_weights=True)
```

Se muestra en la imagen una función directamente sacada del código donde se muestran los cambios previamente explicados.

CAPÍTULO 4: EVALUACIÓN DE RESULTADOS E INTERFAZ DE USUARIO

4.1. Análisis de Métricas y Curvas de Aprendizaje

Tras acabar las épocas de entrenamiento que han sido programadas, el modelo ha demostrado una gran capacidad de generalización. Como se puede observar en las siguientes curvas de aprendizaje su precisión como su pérdida han actuado de una forma estable sin presentar un gran overfitting gracias al uso de técnicas anteriormente explicadas y la normalización por lotes (Batch Normalization).



El modelo alcanzó una **precisión superior al 88%** en el conjunto de validación, con un valor de AUC (Área Bajo la Curva) de **0.93**. Un AUC tan cercano a 1.0 es un indicador excelente en el ámbito médico, ya que confirma que el sistema es capaz de distinguir con gran fiabilidad entre una mamografía con tejido sano y una que presenta una anomalía que puede llegar a ser maligna.

4.2. Interpretación de la Matriz de Confusión

Ahora vamos a mostrar la matriz de confusión la cual, es una herramienta que nos permite de la mejor manera entender el comportamiento del modelo frente a cada clase clínica.

Matriz de Confusión - VALIDACIÓN

Diagnóstico Clínico Real	Maligno	Benigno	Normal
	48	10	0
	27	31	0
	Maligno	Benigno	Normal
Predicción de la IA	0	0	57


Matriz de Confusión - TEST (Datos Inéditos)

Diagnóstico Clínico Real	Maligno	Benigno	Normal
	44	14	0
	24	34	0
	Maligno	Benigno	Normal
Predicción de la IA	0	0	58

En este punto quiero volver a recordar que el sistema ha sido diseñado para una inclinación intencionada hacia la alta sensibilidad. Esto ha sido gracias al ajuste de los pesos de clases lo cual nos ha servido para poder minimizar los falsos negativos. Desde la total ignorancia, pero buscando el lado mas humano asumo que preferimos falsos positivos a negativos ya que los positivos se supone que llevarán una segunda revisión humana y futuras pruebas. El modelo demuestra ser especialmente robusto en la detección de la clase "Normal", lo que permitiría reducir drásticamente la carga de trabajo de los radiólogos al filtrar automáticamente los casos sanos.

4.3. Despliegue Práctico interfaz de “Radiology AI suite”

¿Por qué no probamos lo creado? Eso fue en lo primero que pensé después de ver los gráficos con los resultados del modelo. Por tanto, decidí como buen desarrollador web intentar construir una herramienta funcional:



Esta interfaz permite al usuario generar una nueva placa simulando que ha entrado en la consulta y le han hecho su radiografía. Ojo la tenemos trucada para ver el resultado real ya que es una imagen cogida para test y vemos su clasificación real para ver si nos equivocamos o no y como actúa el modelo. Una vez se genera la placa e introduce el



Centro Oficial FP
Tecnología y Digitalización

nombre del paciente este analiza la imagen y crea un orden de citas preferente en base a la gravedad y confianza de la placa tratando con ello de optimizar lo máximo posible las citas médicas y salvar vidas.

Conclusiones del proyecto

Tras completar este proyecto que tantos dolores de cabeza me ha dado y que empezó con una noticia que me partió cerró el estómago este termina con un sistema funcional- He llegado a una serie de conclusiones que demuestra que la Inteligencia Artificial no solo sirve para programar cosas absurdas o que ayude en redacciones de clase, sino una herramienta para mejorar la vida de las personas.

Los puntos fuertes

- **El "foco" en lo importante:** He comprobado que el Módulo de Atención Espacial funciona. No es solo código; es obligar a la máquina a que mire donde el radiólogo pondría la lupa. Esto se traduce en ese **AUC de 0,93**, que me da la tranquilidad de que el modelo distingue con fiabilidad lo que es peligroso de lo que no lo es.
- **Un modelo que no es "vago":** Gracias a que nos peleamos con el desbalanceo usando Focal Loss y el equilibrio 1:1, he conseguido que la IA no se acomode en decir que "todo es normal". Además, al darle ese peso de 3 a la clase maligna, he logrado que el sistema sea "valiente" y priorice detectar el cáncer por encima de todo.
- **Utilidad real:** No se ha quedado en un gráfico frío. Crear la **Radiology AI Suite** me ha servido para ver que esto podría estar si fuese aún más elaborado y con más material oficial por experto en una consulta, ayudando a cualquier médico a priorizar a las pacientes que más lo necesitan.

Mis puntos débiles: Lo que me gustaría mejorar

- **La vista de la IA:** Por limitaciones de memoria en Colab, tuve que reducir las imágenes a 224x224 píxeles. Siendo sinceros, las microcalcificaciones pueden ser minúsculas y, aunque el modelo las ve, me gustaría entrenarlo con imágenes a resolución completa para no perder ni un solo detalle.



Centro Oficial FP
Tecnología y Digitalización

- **Falta de "charla" con el paciente:** Oye considero que es algo muy importante, durante la realización de este proyecto al ponerme enfermo he recibido la pregunta “¿Algún familiar ha tenido x?”. Al estar dándole vueltas veo que este modelo solo evalúa una foto, un historial médico previo es algo para tener en cuenta aquí bajo mi forma de verlo
- **Dataset limitado:** Aunque mezclar fuentes nos ha servido para este ensayo, me queda la espinita de probar esto con miles de imágenes más de hospitales distintos para asegurar que no se confunde con ningún tipo de mamografía.

Reflexión final y futuro

Este proyecto me ha enseñado que mis dos pasiones la informática y la biología no están separadas, afortunadamente podría combinar mis dos pasiones. En el futuro me encantaría que estas injusticias desapareciesen y nadie tuviese que padecer esta horrible enfermedad.

Como dije al principio, esto es solo mi pequeño grano de arena. Si este sistema fuese estudiado por un experto o simplemente un equipo pudiese tomar esto como base y lograra que una sola mujer en Marchena, o en cualquier parte del mundo, recibiera su tratamiento a tiempo, todo este esfuerzo habría valido la pena. Personalmente me voy satisfecho, he aprendido y disfrutado este proceso.

BIBLIOGRAFÍA

Artículos Científicos y Bases de Datos Oficiales

- **American College of Radiology (ACR).** (2013). *ACR BI-RADS Atlas: Breast Imaging Reporting and Data System*. Reston, VA: American College of Radiology.
- **He, K., Zhang, X., Ren, S., & Sun, J.** (2016). Deep residual learning for image recognition. *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 770-778). (Documento fundamental de la arquitectura ResNet).
- **Lin, T. Y., Goyal, P., Girshick, R., He, K., & Dollár, P.** (2017). Focal loss for dense object detection. *Proceedings of the IEEE international conference on computer vision* (pp. 2980-2988). (Base matemática para el tratamiento del desbalanceo).
- **Nguyen, H. T., et al.** (2022). VinDr-Mammo: A large-scale benchmark dataset for computer-aided diagnosis in full-field digital mammography. *PhysioNet*.
- **Sawyer-Lee, R., et al.** (2016). Curated Breast Imaging Subset of DDSM (CBIS-DDSM). *The Cancer Imaging Archive (TCIA)*.
- **Zuiderveld, K.** (1994). Contrast Limited Adaptive Histogram Equalization (CLAHE). *Graphics Gems IV*, San Diego: Academic Press Professional (pp. 474-485).

Documentación Técnica y Conceptos Clínicos

- **Clínica Universidad de Navarra (CUN).** (s.f.). *Mamografía: Procedimiento, preparación y diagnóstico*. Encontrado en: <https://www.cun.es/enfermedades-tratamientos/pruebas-diagnosticas/mamografia>
- **Keras Team.** (s.f.). *Keras Applications: ResNet e implementaciones*. Documentación oficial de la API. Encontrado en: <https://keras.io/api/applications/resnet/>



Centro Oficial FP
Tecnología y Digitalización

- **Mexopencv.** (s.f.). *Demostración y fundamentos del filtro CLAHE (Contrast Limited Adaptive Histogram Equalization)*. Encontrado en: https://amroamroamro.github.io/mexopencv/opencv/clahe_demo_gui.html

Recursos de Formación y Tutoriales de Apoyo

- **Damavis.** (2021). *Creación de una Red Convolucional con TensorFlow*. Blog de Data Engineering & AI. Encontrado en: <https://blog.damavis.com/creacion-de-una-red-convolucional-con-tensorflow/>
- **DataCamp.** (s.f.). *Tutorial de Redes Neuronales Convolucionales (CNN) con TensorFlow y Python*. Encontrado en: <https://www.datacamp.com/es/tutorial/cnn-tensorflow-python>
- **Sadeddin, S.** (s.f.). *Loss Focal: Una solución para el desbalance de datos*. Blog de Inteligencia Artificial Siria AI. Encontrado en: <https://siriasadeddin.wixsite.com/siriaai/post/loss-focal-una-soluci%C3%B3n-para-el-desbalance-de-datos>
- **YouTube.** (s.f.). *Explicación detallada de la arquitectura ResNet50V2* [Video]. Encontrado en: <https://www.youtube.com/watch?v=KkIr1-fq5fo>